



Universidade Estadual de Maringá
Centro de Tecnologia
Departamento de Informática



**ANÁLISE DE TÉCNICAS TRADICIONAIS VERSUS
APRENDIZADO DE MÁQUINA NA PREDIÇÃO DO MOVIMENTO
DE PREÇOS DE AÇÕES**

DANILO ARREBOLA

TCC-2024

Maringá - Paraná
2024



Universidade Estadual de Maringá
Centro de Tecnologia
Departamento de Informática



**ANÁLISE DE TÉCNICAS TRADICIONAIS VERSUS
APRENDIZADO DE MÁQUINA NA PREDIÇÃO DO MOVIMENTO
DE PREÇOS DE AÇÕES**

DANILO ARREBOLA

TCC-2024

Trabalho de Conclusão de Curso apresentado à Universidade Estadual de Maringá, como parte dos requisitos necessários à obtenção do título de Bacharel em Informática.

Orientador: Prof. Dr. Wagner Igarashi

Banca: Dante Alves Medeiros Filho

Banca: Yandre Maldonado e Gomes da Costa

Maringá - Paraná
2024



Universidade Estadual de Maringá
Centro de Tecnologia
Departamento de Informática



**ANÁLISE DE TÉCNICAS TRADICIONAIS VERSUS APRENDIZADO DE MÁQUINA
NA PREDIÇÃO DO MOVIMENTO DE PREÇOS DE AÇÕES**

DANILO ARREBOLA

Trabalho de Conclusão de Curso apresentado à
Universidade Estadual de Maringá, como parte dos
requisitos necessários à obtenção do título de
Bacharel em Informática.

Aprovada em: __/__/__

BANCA EXAMINADORA

Prof. Dr. Wagner Igarashi

Prof. Dante Alves Medeiros Filho

Prof. Yandre Maldonado e Gomes da Costa

Maringá - Paraná
2024

Dedicatória

Dedico essa pesquisa a algumas pessoas que foram muito importantes para minha jornada:

Primeiramente dedico ela completamente aos meus queridos amigos de faculdade, porque sei que Deus e o destino nos juntaram, tenho certeza que se não fosse por vocês eu não estaria apresentando esta pesquisa. Vocês foram os responsáveis por me manterem neste curso, da qual sabemos que não foi fácil chegar aonde estamos, pois vimos muitos colegas que acabaram desistindo, mas podem ter certeza que vocês fazem grande parte do meu sucesso.

Ademais, dedico à minha família, pelo amor incondicional, pelo apoio constante e por serem minha maior fonte de inspiração. Vocês me ensinaram o valor do esforço e da resiliência.

Agradecimentos

Agradeço em primeiro lugar a Deus que guiou meu caminho durante toda esta pesquisa e toda a caminhada durante este curso.

Queria agradecer ao meu orientador e que um dia já foi meu professor, Prof. Dr. Wagner Igarashi, este que aceitou o meu pedido para me auxiliar nesta pesquisa que já havia tempo que tinha interesse em realiza-lá. Ele foi responsável por me ajudar e me indicar formas de entender o funcionamento do mundo das ações, tarefa que foi difícil para alguém como eu que não possuía conhecimento algum sobre este tema. Ademais, me incentivou em todo o período desta pesquisa e sempre estive ao meu lado sobre qualquer problema que estava passando e me ajudando a encontrar soluções.

Por fim, agradeço a minha amiga Maria Alice Aristides Silva, que também estava realizando a pesquisa na mesma área e que pode compartilhar comigo seu conhecimento sobre economia, além de me ajudar em algumas situações de dificuldade durante a pesquisa.

Epígrafe

“Se você não encontrar um jeito de ganhar dinheiro enquanto dorme, você vai trabalhar até morrer.”

- **Warren Buffett**

Resumo

O mercado de ações existe há centenas de anos. No passado, era um ambiente na qual pensávamos que somente investidores e pessoas com altos níveis de estudo sobre economia e finanças podiam participar. Porém, o avanço da tecnologia e a democratização ao mercado financeiro permitiram que mais pessoas comessem a investir. No entanto, ainda hoje, a comercialização de ações é considerada um investimento de alta volatilidade, e exige conhecimento de ferramentas de análise financeira para auxiliar na tomada de decisões. Especificamente, uma ferramenta bastante reconhecida na literatura é a análise técnica, que é responsável por auxiliar no estudo e investimento de uma determinada ação, com base em análises gráficas sobre o histórico de preços da ação ao longo do tempo. Neste cenário, esta pesquisa teve como objetivo, fazer uma análise e comparar modelos de predição de preço com base em indicadores técnicos e modelos de aprendizagem de máquina (Máquina de Vetores de Suporte e Redes Neurais). Foram realizadas simulações de investimento, as quais tiveram como base de comparação o rendimento da poupança sobre o período estudado, de modo a estabelecer se tais técnicas são viáveis. Após diversos testes, foram analisados os resultados obtidos através dos modelos gerados e visto que foi possível obter resultados lucrativos, principalmente sobre o modelo que utiliza o algoritmo de Máquina de Vetores de Suporte em combinação com a técnica de K-folds, este modelo obteve melhores resultados sobre a taxa de crescimento anual, já o modelo que utiliza apenas os indicadores técnicos para a realização da predição, conseguiu obter o maior lucro após o fim da predição. Através desses modelos, foi visto que possuem capacidade de serem melhores que apenas o investimento na poupança.

Palavras-chave: Mercado de ações, aprendizado de máquina, análise técnica, indicadores técnicos.

Abstract

The stock market has existed for hundreds of years. In the past, it was an environment where we believed that only investors and individuals with high levels of education in economics and finance could participate. However, advances in technology and the democratization of access to the financial market have allowed more people to start investing. Nevertheless, even today, stock trading is considered a high-volatility investment, requiring knowledge of financial analysis tools to assist in decision-making. Specifically, one well-recognized tool in the literature is technical analysis, which helps study and invest in a specific stock based on graphical analyses of the stock's price history over time. In this context, this research aimed to analyze and compare price prediction models based on technical indicators and machine learning models (Support Vector Machines and Neural Networks). Investment simulations were carried out, using the savings account returns over the studied period as a benchmark to determine whether such techniques are viable. After several tests, the results obtained from the generated models were analyzed, and it was found that profitable results were achievable, particularly with the model using the Support Vector Machines algorithm in combination with the K-folds technique. This model achieved better results in terms of annual growth rate, while the model relying solely on technical indicators for prediction achieved the highest profit at the end of the prediction period. Through these models, it was observed that they have the potential to outperform simple savings account investments.

Keywords: Stock market, machine learning, technical analysis, technical indicators.

Lista de ilustrações

Figura 1 - Modelo matemático simples de um neurônio.....	26
Figura 2 - Modelo gráfico sobre margem máxima.....	27
Figura 3 - Representação gráfica do modo kernel.....	29
Figura 4 - Retorno dos dados da ação ITUB4.SA.....	34
Figura 5 - Condição de parada da predição usando RSI.....	35
Figura 6 - Comparação entre as linhas MACD e Signal line.....	36
Figura 7 - Ampliação da Figura 6.....	36
Figura 8 - Condição de parada da predição usando MACD	37
Figura 9 - Laço de repetição para seleção do melhor modelo.....	42
Figura 10 - Momento de compra e venda decidido pelo prediction.....	43

Lista de quadros

Quadro 1 - Porcentagem de rendimento da poupança.....	39
Quadro 2 - Resultados das simulações de investimento.....	40
Quadro 3 - Resultados das simulações com SVM.....	45
Quadro 4 - Resultados das simulações com MLPClassifier.....	46
Quadro 5 - Valores de accuracy, precision e F1-score.....	46
Quadro 6 - Tabela de ranqueamento dos melhores investimentos.....	47

Sumário

1. Introdução.....	12
2. Fundamentação Teórica.....	15
2.1 Análise do mercado.....	15
2.2 Análise fundamentalista.....	16
2.3 Análise técnica.....	17
2.4 Indicadores técnicos	18
2.4.1 Média móvel.....	18
2.4.2 Volume.....	20
2.4.3 Interesse aberto.....	21
2.4.4 Indicador de Força Relativa (IFR).....	21
2.4.5 Média Móvel Convergente/Divergente (MACD).....	22
2.5 Aprendizado de máquina	23
2.6 Redes Neurais.....	25
2.6.1 Máquina de Vetor de Suporte (SVM).....	26
2.7 Estudos correlatos.....	30
3. Materiais e Métodos	32
3.1 Materiais.....	32
3.2 Metodologia.....	32
4. Desenvolvimento.....	34
4.1 Código com apenas indicadores técnicos.....	34
4.2 Código com técnicas de aprendizado de máquina.....	41
4.2.1 Código com SVM.....	44
4.2.2 Código com MLPClassifier.....	45
5. Resultados.....	47
6. Conclusão.....	49
Referências Bibliográficas.....	52

1. Introdução

O investimento na bolsa de valores se tornou uma forma atrativa de obter retorno financeiro para muitas pessoas. No entanto, lucrar por meio desse tipo de investimento não é fácil sem o devido conhecimento técnico. Por isso, investidores e traders buscam métodos matemáticos e estatísticos para prever os preços futuros das ações.

No início, os investidores baseavam suas previsões em intuição e experiência, resultando em limitações como a dificuldade de avaliações precisas e a influência de fatores psicológicos, já que são pessoas, e não modelos perfeitos, que determinam o valor das ações.

Entre as técnicas tradicionais para prever movimentos de preços, a análise técnica se destaca. Ela é considerada um estudo do mercado de ações, baseando-se em decisões que variam conforme a situação atual e requerendo uma avaliação contínua, já que o mercado precede a análise e a resposta. O objetivo da análise técnica é interpretar o histórico de preços de uma ação, para antecipar futuros movimentos com maior probabilidade de acerto. É importante esclarecer que não é possível identificar os preços precisamente, mas sim a tendência deles.

No ambiente do mercado de ações, alguns pontos fundamentais se destacam. Primeiro, temos três indicadores técnicos comumente utilizados: preço, volume e contratos em aberto. Além disso, existem premissas essenciais para o entendimento da análise técnica, como a ideia de que a ação no mercado desconta tudo. Isso significa que fatores fundamentais, políticos, psicológicos ou de qualquer outra ordem podem ser refletidos no preço do mercado.

Outra premissa é que os preços se movem em tendência, ou seja, uma tendência em vigor tem maior probabilidade de continuar do que de reverter. Por fim, a premissa de que a história se repete, baseada na Psicologia Social, sugere que o mercado tende a seguir padrões comportamentais previamente estabelecidos (Lemos, 2012). A agilidade da resposta do analista ou investidor também é crucial, tornando o uso de sistemas computacionais relevante.

Nos últimos anos, a previsão de preços das ações ganhou ainda mais destaque. Além dos métodos estatísticos tradicionais, técnicas inovadoras de aprendizado de máquina surgiram para obter resultados mais precisos e resolver

problemas cotidianos do mercado, visando a um lucro mais consistente (Liou, Huang, 2023).

A motivação para o desenvolvimento desta monografia decorre da percepção de que, embora o mercado de ações possa parecer confuso, ilógico e arriscado, ele pode ser uma fonte adicional de renda. Com isso, surge a oportunidade de conhecer melhor o mercado de ações e de explorar formas de unir o conhecimento sobre aprendizado de máquina e redes neurais para desenvolver maneiras de analisar, com inteligência artificial, os movimentos de preços das ações, possibilitando extrair previsões e decidir se vale a pena investir em uma determinada ação. Ressalta-se que estes modelos não são perfeitos, mas espera-se que possam realizar previsões, indicando potenciais investimentos reais e auxiliando novos investidores a evitarem perdas financeiras.

Diante dessa motivação, foram estabelecidos objetivos para guiar o processo de pesquisa de forma sistemática. O objetivo geral deste TCC é realizar uma análise técnica do mercado de ações, utilizando indicadores técnicos e treinando modelos de aprendizado de máquina como SVM e redes neurais. Além disso, foram definidos objetivos específicos, como identificar os indicadores técnicos mais comumente empregados na literatura, para fundamentar a escolha dos indicadores utilizados na construção dos modelos.

De modo a atingir os objetivos específicos, será demonstrada a criação de um modelo de predição básico, utilizando apenas indicadores técnicos e ajustes de parâmetros, seguido por uma análise detalhada de sua simulação. Com base no conhecimento adquirido, foram construídos modelos mais complexos, utilizando técnicas de aprendizado de máquina. Esses modelos também são baseados em indicadores técnicos e ajustes de parâmetros, com simulações e análises de retorno hipotético.

A performance dos modelos de aprendizado de máquina foi avaliada por meio de métricas tradicionais, permitindo uma comparação objetiva entre os diferentes modelos. Além disso, simulações em um cenário de investimento real, com um intervalo de um ano, foram realizadas para avaliar o desempenho financeiro dos modelos. Por fim, este estudo teve como outro objetivo específico verificar se os modelos de aprendizado de máquina podem aperfeiçoar o processo de predição dos movimentos de preços de ações, em comparação com métodos mais tradicionais.

Além desta seção de caráter introdutório, esta monografia apresenta as seguintes seções: no tópico dois, temos uma visão geral sobre a contextualização do mercado de ações, além de explicar em seguida, sobre o que é e como funciona os indicadores técnicos, ainda sim, no mesmo tópico está sendo abordado os temas de aprendizagem de máquina, redes neurais e máquina de vetores de suporte. Na sequência, temos o terceiro tópico, com o objetivo de abordar os materiais e métodos que foram utilizados durante todo o desenvolvimento desta pesquisa. O quarto tópico, está destinado a explicar de maneira detalhada como ocorreu o processo de desenvolvimento dos códigos utilizados nesta pesquisa, incluindo também os resultados obtidos pelos respectivos testes. O quinto tópico, tem como objetivo ranquear quais foram as melhores técnicas utilizadas durante essa pesquisa e explicar o porquê de alguns resultados.

Por último, é apresentada uma conclusão sobre o que foi possível entender sobre toda essa pesquisa, identificando os pontos positivos e negativos que ocorreram durante este período, além de concluirmos se a utilização das técnicas abordadas podem ser realmente úteis em comparação ao método da poupança que acaba sendo mais seguro, porém com lucros menores.

2. Fundamentação teórica

Indivíduos sem conhecimento prévio sobre o mercado de ações podem desenvolver a percepção de que esse ambiente é análogo a jogos de azar, onde a vitória dependeria unicamente da sorte. Embora esse argumento possua certa validade, dado que o mercado financeiro é extremamente volátil e não há controle absoluto sobre suas flutuações, é crucial destacar que investir requer muito mais do que sorte. É necessário possuir um entendimento dos históricos de preços, volumes de negociação e, até mesmo, compreender o funcionamento interno das empresas cujas ações se deseja adquirir. Além disso, o mercado de ações desempenha um papel fundamental na economia ao permitir que as empresas captem recursos financeiros a um custo mais baixo, possibilitando melhorias e expansão.

2.1. Análise do mercado

A partir de uns anos atrás, investir no mercado de ações começou a ser uma prática utilizada por diversas pessoas para adquirir uma forma de renda extra, porém a ideia de um mercado, na qual as pessoas possam comprar parte das ações de uma empresa ou de um proprietário não é recente, de acordo com Lemos (2012), o surgimento do mercado de ações se deu por meados dos anos de 1600, por meio dos holandeses quando surgiram seis empresas que ficaram conhecidas como “Companhias das Índias”.

Essas empresas eram responsáveis por navios mercantes que faziam expedições para a Índia, porém nesta mesma época a Holanda estava em guerra contra Espanha, por esse motivo necessitavam de muito dinheiro para preparar seus navios com canhões. A partir disso, o governo holandês decidiu unir as seis empresas para formarem uma só estatal, além de convidar o povo para se tornar sócio, nesse momento surgiu a primeira megaempresa do mundo, a Companhia Holandesa das Índias Orientais (do holandês VOC - Verenigde Oost-Indische Compagnie) (Lemos, 2012).

Depois de alguns anos, a ideia do mercado de ações expandiu mundialmente, e nos dias atuais contamos com diversos desafios quando o assunto é investir. Um dos maiores desafios enfrentados diariamente, é a tentativa

de encontrar uma forma de maximizar o lucro e ao mesmo tempo minimizar as possíveis perdas que possam ocorrer. Teoricamente, as ações mais voláteis são as que podem permitir maiores lucros, mas apresentam os maiores riscos também. É importante ressaltar que há vários fatores que influenciam o preço, dentre eles podemos destacar a confiança dos investidores, crises políticas (caso do recente conflito entre Rússia e Ucrânia), econômicas e até mesmo a área da saúde pode influenciar nos preços (caso da pandemia do COVID-19). Situações como crises geram medo e incerteza entre os investidores, tornando assim mais complexa e difícil a tarefa de prever os movimentos de uma ação (Zouaghia, Aouina, Said, 2023).

2.2. Análise fundamentalista

Seguindo a ideia de Lemos (2012), é possível compreender que o mercado de ações é um ambiente volátil, onde, em alguns momentos, o preço de uma determinada ação pode sofrer interferências não previstas por gráficos ou pelo histórico. Isso ocorre porque o mercado é formado por pessoas que compram e vendem, e esses momentos imprevistos podem ocorrer devido a ações impulsivas ou emocionais dessas pessoas, frente a notícias corporativas inesperadas, crises econômicas, mudanças nas políticas governamentais; o que dificulta a previsão de como esses eventos vão refletir sobre as ações.

Por outro lado, Graham (2006), um dos pioneiros da análise fundamentalista, defende esta outra abordagem, onde o objetivo é avaliar o valor intrínseco de um ativo, como uma ação, baseado em fundamentos econômicos e financeiros sólidos. Alguns deles são: fluxos de caixa descontados, índices de preços, lucro, preço ou o valor contábil (Costa, Vargas, 2011). Ao fazer isso, Graham (2006) buscava minimizar a influência dos sentimentos e da impulsividade que muitas vezes afetam os investidores no mercado de ações.

Um problema que possa vir a ocorrer utilizando a análise fundamentalista, é que pode existir uma grande diferença quando se trata de entender o que está acontecendo internamente dentro da empresa, em relação a como esta é percebida pelo mercado em que atua. Isto ocorre porque não é levado em consideração a influência de outros *traders* como variável na análise de um investimento. Como citado anteriormente, algumas situações não possuem uma

explicação lógica, pode ser que as alterações no valor de uma ação foram causadas por momentos de emoções pessoais que as pessoas tiveram por conta de crises financeiras, guerras, epidemias, etc, mas que até o momento não era possível prever (Lemos, 2012).

2.3. Análise técnica

A respeito da análise técnica, segundo Costa e Vargas (2011), ela é uma ferramenta utilizada por pessoas que tem como finalidade estudar os gráficos históricos dos preços e volumes de negociação, sendo assim, por meio desses dados é possível extrair uma conclusão a respeito do ativo, as pessoas que trabalham utilizando a análise técnica são comumente reconhecidos como grafistas.

É importante compreender alguns dos pilares essenciais da análise técnica, de modo a facilitar sua aplicação. O primeiro pilar é “a ação no mercado desconta tudo”. O significado por trás dessa frase é que, o preço de uma ação tem como interferência não apenas questões técnicas de uma empresa, ou um histórico, mas também fatores religiosos, políticos, os quais afetam os preços dessas ações. Por esse motivo, o estudo para investir em ações acaba sendo mais complexo ainda.

O segundo pilar é “os preços movem-se em tendência”, ou seja, ações podem apresentar tendências nos momentos iniciais, assim gerando a possibilidade de tirar proveito do mesmo. Por essa razão, são utilizados gráficos, os quais têm como objetivo ajudar a identificar tendências que venham a ocorrer no futuro. O último pilar a ser destacado, é “a história se repete”. Esse fato acaba sendo explicado pela psicologia social, quando mencionado que ações humanas tendem a se repetir dependendo de padrões comportamentais. Como os preços do mercado são reflexos das ações humanas, logo padrões que vieram a ocorrer no passado, tendem a ter leves alterações ou até permanecerem como antes (Lemos, 2012).

Diferente da análise fundamentalista, a técnica não se preocupa com relação aos fundamentos da companhia (indicadores internos da empresa), tais como os citados anteriormente, é muito mais uma questão de uma análise gráfica sobre o histórico de preços da ação (um indicador resumo e externo) e como é o desempenho ao longo do tempo, sem necessariamente realizar um estudo a fundo

de como é realizar a organização e administração da empresa responsável pelo ativo (Costa, Vargas, 2011).

2.4. Indicadores técnicos

Os indicadores técnicos são os elementos fundamentais da análise técnica e são utilizados para oferecer uma visão diferente para os investidores de como analisar os preços de uma ação, porém é necessário ter conhecimento sobre o que se trata e qual é a verdadeira função que eles podem exercer. De acordo com Lemos (2011):

Um indicador técnico é uma série de dados que são derivados pela aplicação de uma fórmula para os dados dos preços de um título, os quais incluem qualquer combinação da abertura, máxima, mínima ou fechamento de algum período. (p.209)

Dada a definição sobre indicador técnico, é importante definir que uma de suas funções básicas consiste em induzir o investidor a dar mais atenção aos estudos sobre as ações, além de confirmar outras ferramentas de análise técnica e por fim, realizar previsões futuras sobre os preços das ações. Na sequência serão discutidos alguns dos indicadores técnicos já reconhecidos na literatura.

2.4.1.Média móvel

A média móvel, segundo Murphy (2021), é um dos indicadores técnicos mais importantes pelo fato de serem precisos e indiscutíveis. Isso acontece pelo fato de que na prática, é realizada a média de um determinado número de dados históricos. Normalmente, os valores utilizados para o cálculo da média móvel são representados pelo preço de fechamento de seu respectivo dia. Conforme os dias vão passando, os números mais antigos são substituídos pelos novos valores de fechamento conforme uma data de referência.

Tecnicamente a média móvel é compreendida como um dispositivo de seguimento de tendência, ou seja, ele não prevê ações futuras do mercado, mas tem como objetivo identificar que uma nova tendência possa ter começado, ou ainda que uma antiga tenha sido finalizada. Graficamente a média móvel pode ser identificada como uma linha de tendência em curva (Murphy, 2021).

Existem algumas maneiras de realizar o cálculo da média móvel, entre eles os mais utilizados são a média móvel simples (MMS) e a média móvel exponencial

(MME), essas médias tem como objetivo definir possíveis níveis de suporte e de resistência ou ter a capacidade de identificar a direção da tendência (Lemos, 2012). Na sequência serão explanadas as fórmulas para o cálculo da MMS e da MME.

Inicialmente, antes de demonstrar o cálculo sobre a MMS, é importante entender que ela foi um dos primeiros tipos de indicadores técnicos a serem utilizados e que continua a ser utilizado até os dias de hoje, isso ocorre pelo fato de ser um cálculo simples de ser utilizado, mas que possui uma capacidade de auxiliar a reduzir os ruídos, esses ruídos podem ser causados por ações que possuem muita volatilidade em seus preços. Após ter ocorrido essa filtragem dos preços, é possível visualizar de maneira mais suave os preços, tornando assim mais fácil a análise do mesmo e permitindo a identificação de possíveis tendências (Lemos, 2012).

Segundo Lemos (2012), um breve exemplo de como pode ser aplicado a MMS, a fim de auxiliar na compreensão de seu funcionamento, seria o de um cenário hipotético, em que tivéssemos os seguintes sete preços de fechamentos coletados: 11, 12, 13, 14, 15, 16, 17. A partir desses preços, é desejado que seja feita a média sobre um período de cinco dias, começando a partir do primeiro dia de fechamento, escolheríamos os preços onze, doze, treze, quatorze, quinze e somaremos esses valores para em seguida dividir por cinco, obtendo o resultado de número treze da média.

Em seguida, utilizaremos a mesma lógica utilizada no exemplo anterior, porém dessa vez iremos pegar o valor do preço de fechamento de doze a dezesseis e removeremos o valor onze, por ser o preço mais antigo. Efetuando a conta conseguimos atingir o valor de média quatorze e por fim, será feito o mesmo processo de remover o preço mais antigo e adicionar o valor de fechamento mais recente, chegando ao resultado de número quinze. Através desse exemplo é possível compreender que a MMS, acompanha os novos preços de fechamentos e acaba descartando assim o mais antigo.

Tendo exemplificado o funcionamento de como é realizado o cálculo da média, é possível explicar a fórmula para chegar ao resultado. Basicamente, conforme os exemplos anteriores, sempre estamos somando um determinado número de preços de fechamento dos últimos n dias e dividindo esse valor por n , a fórmula acaba sendo representada da seguinte maneira:

$$(C1 + C2 + C3 + \dots Cn)/n \quad (1)$$

Na qual, a letra “C”, é identificada como o preço de fechamento (*close*), e o “n” é interpretado como a quantidade de dias da média móvel, Lemos (2012).

Segundo Lemos (2012), além da MMS, caso o investidor deseje optar por uma opção que reaja de maneira mais sensível aos preços e às mudanças, o ideal seria escolher a média móvel exponencial (MME). Ao utilizar a média móvel exponencial sobre um determinado período, é esperado que possa reduzir o atraso sobre os preços através da aplicação de pesos, sobre os valores de fechamentos mais recentes.

Para aplicar a MME é preciso seguir três etapas, na primeira delas aplicamos a mesma fórmula da MMS, escolhemos a quantidade de dias para definir o período e em seguida selecionamos os respectivos preços de fechamento sobre os dias escolhidos para calcular a média. Após isso calculamos o fator de ponderação e por fim, a própria MME. Para uma situação hipotética, na qual queremos aplicar a fórmula sobre um período de dez dias, fica da seguinte maneira:

MMS: soma de 10 períodos / 10.

Fator de ponderação $(2/(\text{períodos de tempo} + 1)) = (2/(10 + 1)) = 0,1818$

MME: $\{\text{Fechamento} - \text{MMS}(\text{dia anterior})\} \times \text{fator} + \text{MME}(\text{dia anterior})$ (2)

Por meio do resultado obtido, podemos concluir que sobre um período de dez dias, a ponderação seria de 18,18% sobre o preço mais recente de fechamento (Lemos, 2012).

2.4.2. Volume

De acordo com Murphy (2021), o volume é considerado um indicador técnico secundário, isso significa que ele tem como objetivo confirmar uma informação que já foi apresentada anteriormente. Basicamente o volume é uma ferramenta que indica a quantidade de valores mobiliários que foram transacionados em um determinado período, logo se utilizado esse indicador em gráficos de barras, na qual cada barra representa um dia de negociações, o volume será representado por barras verticais que indicam o número de valores negociados naquele dia. O volume

pode também ser utilizado para gráficos com barras que indicam as transações feitas durante a semana, mas não é comumente utilizado para indicar gráficos de barras mensais.

Como o indicador de volume pode ser utilizado da seguinte forma: se o preço da ação está indicando novos máximos, mas o volume está diminuindo, isso pode ser um sinal de uma possível reversão; se o preço está subindo e o volume está aumentando, isso pode ser um sinal para comprar, pois a tendência de alta está sendo confirmada por um aumento no interesse dos investidores.

2.4.3. Interesse aberto

Para um melhor entendimento sobre o que se trata o interesse aberto, é necessário entender sobre o que se trata o termo contrato dentro do contexto do mercado de ações. Estes contratos significam que existem duas pessoas de acordo em fazer negociações, ou seja, um comprador inicia um contrato para uma compra enquanto um vendedor inicia o contrato para a venda. A partir disso, o interesse aberto pode ser interpretado como a quantidade de contratos que estão em circulação durante o respectivo dia, isso não inclui os que foram liquidados ao fim do dia (Murphy, 2012).

2.4.4. Indicador de Força Relativa (IFR)

Conforme citado por Afonso (2023), o indicador de força relativa (IFR, do inglês, *Relative Strength Index* - RSI), é um indicador que foi criado antes mesmo do início da era dos computadores, mas que ainda continua sendo utilizado pelo fato dele ser um oscilador de períodos que tem como finalidade medir a velocidade e a mudança dos movimentos de preço. O funcionamento deste indicador técnico, ocorre da seguinte forma, ele obtém os valores de variação média durante os períodos de alta e de baixa, a partir dessas duas médias, é realizado uma comparação. É importante mencionar que o valor do IFR, pode flutuar entre quarenta e noventa sobre os mercados de alta, tendo suas zonas de suporte podendo variar entre quarenta a cinquenta. Já quando nos referimos a mercados de tendência baixa, os valores podem acabar oscilando entre dez e sessenta, além de possuir uma zona de resistência entre cinquenta e sessenta.

Uma informação que deve ser esclarecida, é que esses intervalos citados anteriormente podem variar de acordo com os parâmetros do IFR, sendo esses parâmetros a força de tendência e a volatilidade do ativo (Lemos, 2012).

O IFR mede o ímpeto dos movimentos de preço de um ativo em uma escala de zero a cem. Leitura acima de setenta por cento indica sobrecompra, e abaixo de trinta por cento, sobrevenda. Sinais de compra e venda são gerados, respectivamente, ao cruzar as linhas de trinta e setenta por cento. O IFR é útil para identificar divergências e confirmar tendências (Afonso, 2023).

A fórmula para encontrar o IFR, segundo Lemos (2012), é a seguinte:

$$IFR = 100 - [100/(1 + RS)] \quad (3)$$

Na qual, o RS significa a média (n) de fechamento de alta (A), dividido pela média (n) de de fechamentos de baixa (B). O (n) indica o período a ser analisado.

2.4.5.Média Móvel Convergente/Divergente (MACD)

De acordo com Tanno (2022), a média móvel convergente/divergente, se trata de uma junção de duas MME para realizar o cálculo.

A respeito desse conteúdo, Murphy (2021), cita que graficamente representamos a MACD através de duas linhas, na qual existe uma que se destaca por ser mais rápida, essa é denominada como linha MACD, para formá-la é necessário realizar o cálculo de duas médias móveis exponenciais e suavizá-las a partir do preço de fechamento da mesma, o período de fechamento desses preços pode variar entre doze à vinte e seis dias ou semanal. A respeito da segunda, ela é reconhecida como linha mais lenta ou linha de sinal, neste caso, ela é resultado de uma média exponencial que foi suavizada a partir de nove períodos da linha MACD.

A partir do cruzamento dessas duas linhas é possível definir um sinal de compra ou venda. Caso a linha MACD cruze acima da linha de sinal mais lenta, significa que é um momento de compra. Porém, caso o oposto aconteça e a linha mais rápida cruze abaixo da linha mais lenta, é um indicativo para vender (Murphy, 2021).

Para representar a teoria sobre o MACD, a fórmula é a seguinte:

$$MACD_t(n1, n2) = EMA_t(n1) - EMA_t(n2) \quad (4)$$

Nesta fórmula o t representa um tempo como valor de índice. Já a respeito dos valores de $n1$ e $n2$, o primeiro indica o período mais curto e o segundo o período mais longo, respectivamente (Kang, 2021).

2.5. Aprendizado de máquina

Após ter compreendido alguns dos possíveis indicadores técnicos que podem ser utilizados na decisão de investimentos e a respeito de como é feita a análise sobre o mercado de ações, é importante salientar que utilizaremos o conhecimento sobre aprendizagem de máquina, para auxiliar na análise do mercado.

O aprendizado de máquina se trata basicamente de um processo em que um computador automaticamente aprende a executar tarefas específicas, com base em dados históricos. De modo geral, quanto mais experiência ou conhecimento fornecermos a este computador, antes do mesmo realizar a tarefa, é esperado que seu desempenho seja melhor, do que caso não tivéssemos fornecido nenhum tipo de conhecimento base antes do início da atividade.

Durante o processo de aprendizado de máquina Farhat *et al.* (2020), citam que para obtermos mais sucesso e precisão nos resultados, é importante seguir uma sequência de sete etapas. A primeira etapa consiste na coleta de dados, porém muitos dos dados quando coletados, podem estar desorganizados, cheios de ruídos ou em formatos incompatíveis, nesse momento, entra o pré-processamento, responsável por limpar e organizar os dados para que o aprendizado possa dar andamento sem que ocorram interferências de dados incompletos, faltantes ou errôneos. Com os dados prontos, a segunda etapa é a engenharia de recursos, ela é responsável por extrair as características mais relevantes dos dados e após isso, escolher qual seria o melhor algoritmo para resolver a tarefa proposta (classificação, regressão, clusterização, etc).

Em seguida temos a etapa do treinamento, neste momento temos como objetivo utilizar uma parte dos dados que foram recebidos e filtrados, para que seja possível melhorar a capacidade do computador em aprender. Depois de concluído o treinamento, é necessário testar o modelo e verificar seu desempenho com outra parte dos dados que não foram utilizados anteriormente (dados de teste). A

performance é avaliada por meio de várias medidas, como acurácia (*accuracy*), precisão (*precision*), revocação (*recall*), medida F (*F-Measure* ou *F-Score*), etc. Em alguns casos, é possível retornar no processo e melhorar o treinamento, para em seguida realizar novos testes. A etapa final é no momento em que o modelo resultante do aprendizado de máquina é utilizado para uma tarefa, que pode ser uma previsão ou inferência (Farhat *et al.*, 2020).

Segundo Cunha (2019), a validação cruzada (*cross-validation*) é um método que auxilia na divisão de bases, gerando assim, amostras de treino e validação, de acordo com essa lógica, serão feitas em bases diferentes a criação do preditor e avaliação do seu risco. Atualmente existem vários modelos de validação que podem ser utilizados, entre eles temos o K-fold, Hold-Out, Leave-one-out e Bootstrap, porém para esta monografia abordaremos apenas o K-fold e Hold-Out.

A validação cruzada K-fold é uma técnica que consiste em um conjunto de dados particionados em k subconjuntos de tamanhos semelhantes, denominados dobras. Em cada iteração, um dos subconjuntos é reservado para testes, enquanto os demais são utilizados para treinar o modelo. Esse processo é repetido k vezes, de modo que cada dobra seja utilizada exatamente uma vez como conjunto de teste. Ao final, as métricas de desempenho obtidas em cada iteração são combinadas, geralmente por meio de uma média, para fornecer uma estimativa mais confiável do desempenho do modelo. Para garantir que cada dobra seja uma representação do conjunto de dados original, é comum realizar uma estratificação antes da divisão, assegurando que a distribuição das classes seja semelhante em todas as dobras (Yadav e Shukla, 2016).

Já com relação a validação Hold-Out, ela é uma técnica na qual os dados são particionados em dois conjuntos mutuamente exclusivos: um conjunto de treinamento, utilizado para ajustar os parâmetros do modelo, e um conjunto de teste, reservado para avaliar o desempenho do modelo em dados não vistos durante o treinamento, esta parte é conhecida como hold-out. A proporção entre os conjuntos pode variar, mas uma divisão comum é de oitenta por cento para treinamento e vinte por cento para teste. É importante ressaltar que a qualidade da avaliação depende da representatividade do conjunto de testes em relação ao conjunto de dados original. Em comparação ao método de validação cruzada K-fold, o tempo que o Hold-Out leva para aprender o modelo é relativamente menor do que o anterior (Yadav e Shukla, 2016).


Em aprendizado de máquina existem algumas técnicas que podem ser classificadas de acordo com o tipo de *feedback* utilizado, entre elas temos a aprendizagem não supervisionada, nesse caso o agente identifica padrões nos dados de entrada sem receber *feedback* explícito. A tarefa mais comum nesse tipo de aprendizagem é o agrupamento, onde se detectam grupos de exemplos de entradas que podem ser úteis. Na aprendizagem por reforço, o agente aprende a partir de recompensas ou punições. Um outro modelo, seria a aprendizagem supervisionada, o agente observa pares de entrada e saída e aprende uma função que mapeia a entrada para a saída (a saída é o *feedback* utilizado para treinar o modelo). Na aprendizagem semissupervisionada, são fornecidos alguns exemplos rotulados e o objetivo é utilizar uma grande quantidade de exemplos não rotulados, os rótulos podem não ser totalmente precisos (Russel e Norvig, 2013).

2.6. Redes Neurais

De acordo com Kong e Zhu (2018), a ideia por trás de uma rede neural veio dos neurônios existentes no cérebro humano, pelo fato de serem responsáveis por receber e enviar estímulos entre os outros neurônios interligados. Se tratando agora da questão das redes neurais artificiais (RNA), o funcionamento teórico se assemelha um pouco a de um neurônio, ela recebe diversos valores, passa esses valores por uma função de entrada, em seguida por uma de ativação e por fim é gerado um valor de saída, essas divisões pela qual os valores passam, podem ser denominadas como camadas ocultas e uma camada de saída.

De início, a camada de entrada consiste em múltiplos neurônios, onde cada um recebe um valor de uma característica específica e gera um valor de saída. Nas camadas seguintes, reconhecidas também como ocultas, os neurônios utilizam as saídas da camada anterior como suas entradas. Cada neurônio combina essas entradas de maneira única, graças a diferentes pesos de combinação. Esses pesos são ajustados durante o treinamento com um conjunto de dados. Finalmente, a camada de saída reúne as saídas da última camada intermediária para produzir o resultado final (Kong, Zhu, 2018). A figura 1 é uma representação de um modelo matemático simples de um neurônio, seguindo a explicação anterior de como ocorre a separação das redes neurais artificiais.

Figura 1. Modelo matemático simples de um neurônio



Fonte: Russel, Norvig (2013).

Outra questão importante a se considerar em relação a RNAs é o formato em que estas redes são estruturadas. Existem duas opções principais: redes de alimentação direta (*feed forward*) e redes recorrentes.

Segundo Russel e Norvig, uma rede de alimentação direta possui conexões unidirecionais, formando um grafo acíclico dirigido. Cada nó recebe entradas de nós anteriores e envia saídas para nós subsequentes; não há ciclos. Normalmente, essas redes são organizadas em camadas, onde cada unidade obtém entradas apenas das unidades da camada anterior. Uma rede de alimentação direta representa uma função de sua entrada atual, sem manter estado interno além dos próprios pesos.

Em contraste com as redes de alimentação direta, uma rede recorrente realimenta suas entradas a partir de suas saídas. Isso cria um sistema dinâmico onde os níveis de ativação podem estabilizar-se, oscilar ou exibir comportamento caótico. A resposta de uma rede recorrente a uma entrada específica depende de seu estado inicial, que pode ser influenciado por entradas anteriores. Assim, redes recorrentes podem manter memória de curto prazo, tornando-se mais adequadas como modelos do cérebro, mas também mais complexas de compreender (Russel, Norvig, 2013).

2.6.1. Máquina de Vetor de Suporte (SVM)

A máquina de vetor de suporte, também conhecida como SVM, é um algoritmo com capacidade de aprendizado supervisionada, que pode ser utilizado tanto em modo de regressão quanto de classificação. Segundo Vapnik (2000):


A máquina de vetores de suporte (SV) implementa a seguinte ideia: Ela mapeia os vetores de entrada x em um espaço de características de alta dimensionalidade Z por meio de algum mapeamento não linear, escolhido a priori. Nesse espaço, um hiperplano separador ótimo é construído.

De acordo com Russel, Norvig (2013), o SVM atualmente é uma das abordagens mais amplamente utilizadas para aprendizado supervisionado, com isso, existem três características principais que acabam chamando a atenção. A primeira, seria que os SVMs, criam um separador de margem máxima, ou seja, uma fronteira de decisão que mantém a maior distância possível dos pontos de dados. Contribuindo significativamente para sua capacidade de generalização.

Além dessa característica, os SVMs utilizam uma técnica conhecida como modo kernel, que permite mapear os dados para um espaço de características de alta dimensão, onde a separação linear se torna viável. Ao retornar ao espaço original, esse hiperplano (superfície de decisão que separa os dados em duas classes distintas), de separação em alta dimensão corresponde a uma superfície de decisão não linear, aumentando significativamente a capacidade de modelar complexidades nos dados. A terceira característica, cita que mesmo os SVMs utilizando um método não paramétrico, método que guarda um conjunto de exemplos de treinamento, eles frequentemente utilizam apenas um subconjunto dos dados de treinamento para construir o modelo, o que os torna computacionalmente eficientes e menos suscetíveis a *overfitting* (Russel, Norvig, 2013).

Segundo Bishop (2006), um dos conceitos presentes no SVM, é a respeito da margem máxima, nele o objetivo é maximizar a distância entre os pontos mais próximos de cada classe e a fronteira de decisão (hiperplano), para garantir uma melhor separação possível entre as classes e melhorar a generalização do modelo para futuros dados. Esta separação ocorre por meio da margem, que é um conceito definido como a menor distância entre a fronteira de decisão e qualquer ponto de dados do conjunto de treinamento.

Figura 2. Modelo gráfico sobre margem máxima



Fonte: Bishop (2006).

Na figura 2 é possível ver claramente como o conceito de margem está sendo aplicado, no caso, ele está definido como a distância perpendicular entre a fronteira de decisão e os pontos mais próximos de cada classe. Além disso, é possível ver algumas atribuições acima das linhas, que são: $y = 1$, $y = 0$ e $y = -1$, os valores identificados como menos um e um, são como rótulos de para cada classe e o zero é uma representação da linha de separação (Bishop, 2006).

A partir do conhecimento adquirido, é possível encontrar a maximização da margem através das seguintes fórmulas:

$$\frac{t_n y(x_n)}{\|w\|} \quad (5)$$

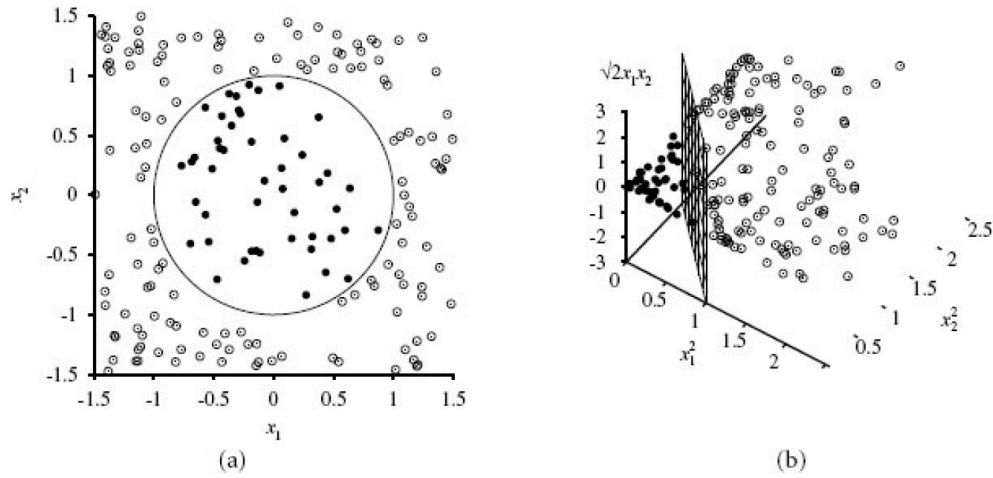
Na fórmula 5, estamos representando t_n como o rótulo da classe(+1 ou -1) sobre o ponto x_n , em seguida, o termo $y(x_n)$ é compreendido como o valor da função de decisão para o ponto x_n e por último, $\|w\|$ é a norma do vetor de pesos w , que define a orientação da fronteira de decisão. Através desta fórmula conseguimos obter a distância perpendicular de um x_n até a fronteira de decisão. O principal objetivo do SVM é maximizar a margem, como consequência é preciso minimizar a norma do vetor de pesos w , por conta disso utilizamos a seguinte fórmula para resolver o problema de otimização:

$$\arg \max (w, b) \left\{ \frac{1}{\|w\|} \min(n) \left[t_n \left(w^T \phi(x_n) + b \right) \right] \right\} \quad (6)$$

Na fórmula 6, estamos representando $w^T \phi(x)$ como um produto interno entre o vetor de pesos w e a transformação dos dados de entrada $\phi(x)$, e o valor b é interpretado como o parâmetro de viés, que define o deslocamento da função de decisão.

Conforme citado por Russel, Norvig (2013), um segundo conceito utilizado no SVM, é o truque kernel, este método é utilizado em problemas em que não há um separador linear, um exemplo que possa representar este método é a figura 3 (a), pelo fato de ser um gráfico com dados positivos ($y = +1$) dentro da região circular, juntamente com dados negativos ($y = -1$), fora da região.

Figura 3. Representação gráfica do modo kernel



Fonte: Russel, Norvig (2013).

É possível notar que na figura 3 (b), foi utilizado os mesmos dados presentes no gráfico (a), porém foi preciso mapear de forma tridimensional, assim possibilitando ver que os dados estão sendo linearmente separáveis. A ideia geral do truque kernel é que, caso os dados consigam ser mapeados em um espaço de dimensão suficientemente alta, quase sempre será encontrado um separador linear para dividir.

Para que seja possível realizar os cálculos a fim de encontrar os separadores lineares, em um espaço de características de dimensão superior, representamos o mesmo como $F(x)$, assim conseguimos substituir o produto escalar de $x_j * x_k$ por $F(x_j) * F(x_k)$. Através dessa transformação, conseguimos calcular diretamente $F(x_j) * F(x_k)$ sem a necessidade de computar explicitamente $F(x)$ para cada ponto de dados. Esse cálculo só é possível através da função kernel, no caso citado anteriormente, podemos aplicar a função que ficaria da seguinte maneira:

$$K(x_j, x_k) = (x_j * x_k)^2 \quad (7)$$

Através da fórmula 7, é possível calcular o produto escalar no espaço de características sem precisar mapear cada dado individualmente (Russel, Norvig, 2013).

2.7. Estudos correlatos

Durante os últimos anos, diversos estudos foram realizados sobre a utilização de aprendizado de máquinas e redes neurais, para a análise do mercado financeiro. Um desses estudos foi realizado por Silva (2022), em sua pesquisa ele utiliza duas técnicas para avaliar a predição do movimento de preços, porém neste caso, ele está fazendo essa predição sobre o mercado chinês.

Em seu estudo, ele faz uso de dois modelos para verificar a predição e qual delas consegue se destacar, no primeiro modelo ele utilizou o valor de fechamento, volume negociado e a variação sobre o dia anterior, além disso, foram utilizados indicadores técnicos e médias móveis. Enquanto no segundo modelo, foram extraídos dados do mercado chinês, mais especificamente da ação VIVT3, mas a lógica utilizada neste modelo seguia os mesmos princípios do anterior, um detalhe a ser mencionado, é que foram selecionadas diferentes *seeds* com valores constantes para a comparação dos resultados obtidos.

O resultado final desse estudo foi de que o segundo modelo, que possuía informações sobre as ações da China, teve um resultado positivo melhor em relação ao primeiro modelo que possuía apenas indicadores técnicos, mesmo o primeiro obtendo alguns resultados negativos (Silva, 2022).

Um segundo estudo, o de Sarika *et al.* (2023), teve como premissa, desenvolver um modelo de inteligência artificial com funcionalidade de estimar os preços das ações de uma determinada ação, utilizando a técnica de *Long Short Term Memory* (LSTM). Durante o desenvolvimento do modelo foram feitos testes utilizando apenas a técnica de LSTM de maneira isolada. Além disso, foram feitos testes combinando LSTM com *Principle Component Analysis* (PCA), que tem como objetivo reduzir a dimensionalidade que transforma os atributos originais em um novo conjunto de atributos, chamados de componentes principais, e utilizando *Recursive Feature Elimination* (RFE), responsável por identificar os subconjuntos mais relevantes que possam contribuir para a precisão do modelo, enquanto elimina os menos importantes.

A análise final, após terem feitos diversos testes, foi que o modelo que combinou o LSTM com RFE e PCA, obteve mais precisão em relação ao modelo que utilizou apenas o LSTM de maneira isolada (Sarika *et al.*, 2023).

Outro estudo que teve como foco a utilização de inteligência artificial sobre o mercado de ações, com o objetivo de auxiliar no desenvolvimento de ferramentas para contribuir na decisão de compra e venda dos investidores, foi desenvolvido por Afonso (2023). Nesta pesquisa ele coletou dados a partir de uma *API (Application Programming Interface)* do *Yahoo Finance*, nestes dados estavam presentes informações sobre preços de fechamentos, aberturas, máxima, mínima e volumes de negociações sobre um período específico, que no caso, seria utilizado para o treinamento dos modelos, em seguida outros dados foram coletados, porém sobre um período de tempo menor, diferente e mais recente, que no caso deste cenário, seria utilizado para a avaliação de desempenho. Durante o pré-processamento dos dados, foram utilizados alguns indicadores técnicos, como por exemplo: MMS, MME, MACD e IFR.

A conclusão obtida a partir dos modelos desenvolvidos para esta pesquisa, foi de que tanto quanto o modelo que utilizava máquina de vetores de suporte (do inglês, *Support Vector Machine* - SVM) ou o de redes neurais, ambos obtiveram vantagens e desvantagens sobre os diversos cenários, mas foi possível notar que o modelo com SVM obteve resultados melhores em relação às redes neurais (Afonso, 2023).

Com base nos estudos correlatos, pode-se verificar a viabilidade de se analisar a aplicação de análise técnica e técnicas de aprendizagem de máquina na predição do movimento de preços de ações, o qual é tema desta pesquisa.

3. Materiais e Métodos

3.1. Materiais

Durante esta sessão, são abordados os materiais utilizados para a realização deste trabalho, dentre eles incluindo o equipamentos de *hardware* e quais *softwares* foram empregados nas simulações experimentais.

A respeito do *hardware*, foi utilizado um computador *desktop* com as seguintes especificações:

- Processador Intel(R) Core(TM) i5-9400F CPU @ 2.90GHz
- Memória RAM de 16,0 GB
- SSD de 480GB
- Sistema Operacional Windows 10 Pro - 64 bits

A respeito da linguagem de programação utilizada para desenvolver os modelos, foi selecionada a linguagem Python.

Durante o desenvolvimento do modelo foi utilizada a biblioteca Pandas do python, que é especializada na manipulação e análise de dados. Em relação à a biblioteca Pandas, foi utilizado especificamente o DataFrame, que consiste de uma estrutura de dados bidimensional similar a uma planilha do Excel, que permite armazenar e manipular grandes conjuntos de dados de forma eficiente.

O Pandas foi então utilizado para ajudar a manipular os dados financeiros das empresas Banco do Brasil e Itaú obtidos do Yahoo Finance, um portal de informações financeiras, notícias e ferramentas para auxiliar usuários em seus investimentos e decisões financeiras. Este portal oferece uma ampla gama de recursos para atender às necessidades de investidores.

Além do Pandas, foi utilizada a biblioteca scikit-learn que oferece um conjunto abrangente de algoritmos e ferramentas para tarefas de aprendizado de máquina, permitindo o treinamento, teste e avaliação de modelos necessários à predição do movimento de preços das ações das empresas selecionadas.

3.2. Metodologia

Para a metodologia deste estudo, inicialmente foi realizado um levantamento, com finalidade de escolher alguns indicadores técnicos que são mais utilizados na literatura. Em seguida, foi definido um modelo de predição que utiliza

exclusivamente os indicadores técnicos selecionados na etapa anterior, ajustando seus parâmetros conforme necessário e realizando simulações do modelo proposto. Com base no conhecimento adquirido na etapa passada, foram desenvolvidos modelos de aprendizado de máquina, que também se baseiam nos indicadores técnicos, com ajustes de parâmetros e simulações subsequentes.

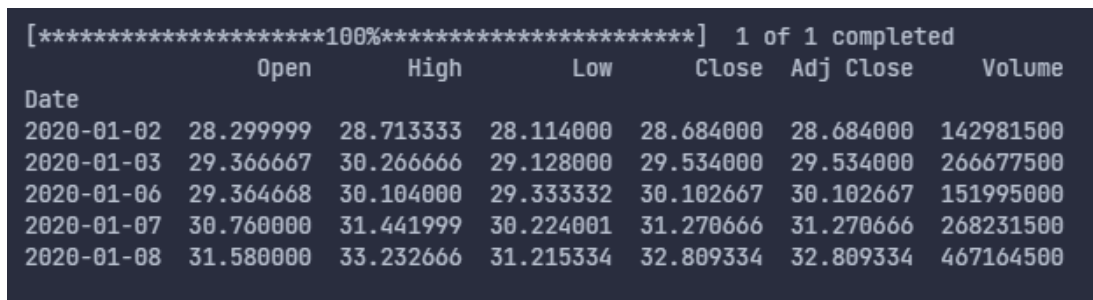
A performance dos modelos de aprendizado de máquina são então avaliados utilizando técnicas tradicionais de avaliação da área de aprendizagem de máquina. Posteriormente, os modelos são simulados em investimentos reais ao longo de um intervalo de um ano, e os resultados financeiros obtidos são comparados. Finalmente, após o desenvolvimento do modelo, testes e simulações, é realizada uma análise detalhada dos valores finais, permitindo uma compreensão mais profunda da eficácia dos modelos desenvolvidos.

4. Desenvolvimento

Foram selecionadas as ações da Itaú Unibanco Holding S.A. (ITUB4.SA), juntamente com a do Banco do Brasil S.A. (BBAS3.SA), para realizar a análise proposta nesta pesquisa. De início, foi realizada a importação da biblioteca *yfinance*, essa é uma biblioteca do próprio *site* Yahoo Finance, através dela é possível coletar dados referentes a cada uma das ações escolhidas.

Adiante foram selecionadas as datas referentes ao período de treinamento. Estas datas são a partir de primeiro de janeiro de dois mil e vinte até trinta e um de dezembro de dois mil e vinte dois. Após isso, realizamos a importação dos dados referentes ao período e tendo como retorno o dia daquela ação, o valor da abertura (*Open*), fechamento (*Close*), além de qual foi o maior valor (*High*) daquele dia, o menor (*Low*), por fim temos também qual foi o volume (*Volume*) obtido.

Figura 4. Retorno dos dados da ação ITUB4.SA

A screenshot of a terminal window displaying stock data for ITUB4.SA. The terminal has a dark background with light-colored text. At the top, it shows a progress bar at 100% and '1 of 1 completed'. Below this, a table of stock data is displayed with columns for Date, Open, High, Low, Close, Adj Close, and Volume. The data covers the first five trading days of 2020.

Date	Open	High	Low	Close	Adj Close	Volume
2020-01-02	28.299999	28.713333	28.114000	28.684000	28.684000	142981500
2020-01-03	29.366667	30.266666	29.128000	29.534000	29.534000	266677500
2020-01-06	29.364668	30.104000	29.333332	30.102667	30.102667	151995000
2020-01-07	30.760000	31.441999	30.224001	31.270666	31.270666	268231500
2020-01-08	31.580000	33.232666	31.215334	32.809334	32.809334	467164500

Na figura 4, é possível visualizar como é o retorno dos dados referente a ação ITUB4.SA, neste caso, ele está trazendo apenas as principais informações de preço dos cinco primeiros dias a partir de 02/01/2020.

4.1. Código com apenas indicadores técnicos

Neste primeiro momento, foi aplicado o conhecimento adquirido sobre como é o funcionamento dos indicadores técnicos, no contexto das ações ITUB4.SA e BBAS3.SA, além disso, foram obtidos os dados das ações entre os períodos do dia primeiro de janeiro de dois mil e dezenove até trinta e um de dezembro de dois mil e vinte e dois, mas para realizar os cálculos utilizamos uma estimativa de um ano apenas, logo o término dos cálculos seriam no dia dois de janeiro de dois mil e vinte.

Foram desenvolvidos três códigos nesta fase do estudo utilizando os indicadores técnicos, no primeiro foi utilizado apenas os valores de RSI para delimitar os momentos de vendas ou compras. Neste código, existe um laço de

repetição que está percorrendo o valor de todos os dias das ações, existe um parâmetro informando se é um momento de compra ou venda, além disso, é validado se esse mesmo parâmetro e o valor de RSI é condizente com o escolhido, caso as validações sejam verdadeiras, é realizada uma venda ou uma compra.

Foi desenvolvido um método para interromper o laço de repetição como é possível verificar no código apresentado na Figura 5, no momento em que o código ultrapassa um ano, então é ativado um parâmetro para identificar que caso exista ações para serem vendidas, a próxima venda será a última, ou se a última atividade realizada foi uma venda, então o ciclo é encerrado e mostrado o valor total obtido através dos investimentos feitos no período pré suposto, juntamente com a data da última venda.

Figura 5. Condição de parada da predição usando RSI




```
1  if i == pd.Timestamp('2020-01-02'):
2      fimDeAno = True
3
4      if fimDeAno:
5          if not momentoCompra and row['RSI'] > 75:
6              precoVenda = row['Close']
7              montante = qtdAcoes * precoVenda
8              qtdAcoes = 0
9              dataVendaFinal = i
10             break;
11
12         elif momentoCompra:
13             dataVendaFinal = dataLastSell
14             break
```

O valor setenta e cinco presente na Figura 5, não é um valor estático, ele sofreu diversas alterações durante os testes, a fim de encontrar o melhor parâmetro que gerasse mais lucro para aquele período. Neste caso, que foi utilizando a ação BBAS3.SA, o valor setenta e cinco obteve mais sucesso para o momento da venda.

Adiante foi desenvolvido um segundo código, que tem como objetivo utilizar apenas os indicadores técnicos de MACD para realizar as compras e vendas, juntamente com a sua linha de sinal que é gerada a partir de uma média exponencial suavizada de 9 períodos da linha MACD. Na Figura 6, é possível identificar através de um gráfico a diferença entre a linha MACD (linha mais rápida), identificada pela cor azul e a linha de sinal (linha mais lenta), identificada pela cor laranja. Segundo Murphy (2021), quando a linha mais rápida cruza a linha mais lenta no sentido para


cima, está indicando um momento de compra e quando a linha mais rápida cruza a linha mais lenta para baixo, significa que está indicando um bom momento para venda. Por meio da Figura 6 é possível identificar vários momentos em que estão ocorrendo esses cruzamentos, importante destacar que para ela, foi determinado um período de um ano, ou seja, a partir do início de dois mil e dezenove até dois mil e vinte.

Figura 6. Comparação entre as linhas MACD e Signal line



A Figura 7 é um recorte da Figura 6 de maneira mais ampliada, ela foi marcada para demonstrar o momento exato em que ocorre o cruzamento entre a linha azul (MACD) e a linha laranja (linha de sinal). Neste momento, a melhor opção seria vender todas as ações, pois é possível ver que houve um crescimento no valor da ação anteriormente e no momento, está tendo uma queda, desvalorizando assim o preço.

Figura 7. Ampliação da Figura 6



Todas as transações foram feitas baseadas no valor do MACD e da linha de sinal, inclusive no momento em que a variável que está sendo utilizada como

condição de parada é ativa, a validação também está sendo feita com base nos valores de MACD e linha de sinal. Para este código foi analisado que não conseguimos obter muito lucro, chegando a ter um valor de prejuízo ao final da predição.

Como último experimento, foi desenvolvido um terceiro código, combinando a validação de compra e venda a partir dos valores de RSI, presente no primeiro código e quando a condição de parada for ativada, a próxima venda será baseada no cruzamento entre as linhas de MACD e de sinal.

No código apresentado na Figura 8, é possível ver como está ocorrendo a validação entre o valor de MACD e a linha de sinal. Por meio do código apresentado verifica-se quando ocorre o cruzamento entre esses dois valores, assim é possível perceber que os valores do MACD estão em declínio e que é um bom momento para realizar as vendas antes que os preços fiquem inviáveis.

Figura 8. Condição de parada da predição usando MACD



```
1  if i == pd.Timestamp('2020-01-02'):
2      fimDeAno = True
3
4      if fimDeAno:
5          if not momentoCompra and row['MACD'] < row['Signal_Line']:
6              precoVenda = row['Close']
7              montante = qtdAcoes * precoVenda
8              qtdAcoes = 0
9              dataVendaFinal = i
10             break;
11
12         elif momentoCompra:
13             dataVendaFinal = dataLastSell
14             break
```

Foram feitos diversos testes nos três códigos, alterando a data de fim de ano e valores de RSI, para verificar qual dos dois obtinha maiores retornos de investimentos. Por meio dos testes foi possível visualizar que o terceiro código que utiliza as validações de RSI, juntamente com validação de fim de ano do MACD, foi possível obter maior retorno após os investimentos, em relação ao primeiro código que possuía apenas validações com RSI, enquanto o segundo que estava trabalhando apenas com os valores de MACD e linha de sinal. Estes códigos não

conseguiram obter um resultado melhor, chegando em alguns casos apenas com o primeiro código a alcançar o mesmo valor final.

Com base nos diversos testes realizados no terceiro código envolvendo os indicadores técnicos de RSI e MACD, foi encontrado alguns valores que poderiam ser utilizados para ambas as ações e mesmo assim, sendo possível obter uma porcentagem positiva de lucros a partir de um investimento inicial de cem mil reais. Para esses testes, foi alterado o período de investimento, neste caso estaremos trabalhando com um período de cinco anos e dez meses, ou seja, a partir do dia um de janeiro de dois mil e dezenove até dia vinte e um de outubro de dois mil e vinte e quatro, tendo definido esse período, escolhemos a data do dia dois de janeiro de dois mil e vinte quatro como limite para realizar as transações e ativar o parâmetro de fim de ano. Este parâmetro de fim de ano, está sendo responsável por impedir qualquer outro tipo de compra, ademais existe a possibilidade de que no fim do ano, o valor da ação não esteja alto o bastante para realizar uma boa venda, logo ele vai analisar o melhor momento futuro para vender todas as ações, assim gerando mais lucros.

O código estava configurado, com o valor quatorze para o período utilizado no cálculo do RSI, além disso, foi necessário calcular o valor das médias móveis exponenciais (EMA) antes de obter o valor referente ao MACD, para isso, foi definida uma média móvel exponencial com uma janela de suavização de valor doze e uma segunda média com o valor da janela de vinte e seis. Tendo encontrado os valores respectivos para cada EMA, foi subtraído o EMA de menor valor pelo de maior valor, assim chegando no resultado do MACD. Com o valor do MACD, utilizamos o mesmo cálculo da média móvel exponencial, só que nesse momento, com o valor da janela de suavização igual a nove para encontrar o resultado da linha de sinal.

Antes de demonstrar os resultados obtidos pelos algoritmos, serão apresentados os dados do Quadro 1, referente ao rendimento da poupança durante um período de quatro anos, tendo como valor inicial um investimento de cem mil reais. Assim, é possível ter uma base real de um rendimento anual, além de ser considerado um investimento mais seguro, a fim de comparar os resultados obtidos em simulações por meio do código envolvendo apenas indicadores técnicos. Os dados foram extraídos de acordo com o Brasil Indicadores (2024), sobre o histórico de rendimento anual acumulado de acordo com a regra atual da poupança. Os

valores ainda foram validados juntamente ao site do Banco Central do Brasil (2024), com os valores respectivos de rendimento mensal sobre cada ano.

Quadro 1. Porcentagem de rendimento da poupança

Período	Porcentagem de rendimento (% a.a.)	Investimento
2019	4,2576	R\$ 104.257,60
2020	2,1121	R\$ 106.459,62
2021	2,9861	R\$ 109.638,62
2022	7,8997	R\$ 118.299,74
2023	8,0363	R\$ 127.806,66

Por meio do Quadro 1, foi possível notar que após o fim do ano de dois mil e vinte e três, o resultado final do investimento foi de cento e vinte sete mil oitocentos e seis reais e sessenta e seis centavos. Ainda pode-se utilizar a fórmula da Taxa de Crescimento Anual Composta (do inglês, *Compound Annual Growth Rate* - CAGR - Taxa de Crescimento Anual Composta):

$$CAGR = \left(\frac{ValorFinal}{ValorInicial} \right)^{\frac{1}{n}} - 1 \quad (8)$$

para calcular e verificar que houve uma taxa média de crescimento anual composta de 5,02% ao ano.

O Quadro 2, a seguir, está informando quais foram os valores de RSI utilizados para os momentos de compra e venda, indicando a sua respectiva ação, além do resultado obtido para o período de cinco anos. Como citado anteriormente, para estes resultados foi utilizado o código que possui os indicadores técnicos de RSI para validar o melhor momento de compra e venda, além de ser utilizado também o indicador técnico de MACD, porém para ele foram utilizados valores fixos pelo fato, na qual é necessário calcular o valor das EMA's anteriormente, diante disso, foi definido um valor de doze e de vinte para a janela de suavização das médias, respectivamente. Adiante, com os valores obtidos, foi feita a subtração para chegar ao resultado do MACD. Por fim, foi feito o mesmo cálculo da EMA, mas com o valor da janela de suavização igual a nove para encontrar o resultado da Linha de Sinal.

Quadro 2. Resultados das simulações de investimento

Ações	Valor de Indicadores		Resultados	Média de lucro anual	Porcentagem de lucro anual (% a.a)
	RSI_Compra	RSI_Venda			
BBAS3.SA	17	83	155.072,16	11.014,43	9,17
ITUB4.SA	25	82	155.103,00	11.020,60	9,17
ITUB4.SA	20	82	111.807,00	2.361,40	2,25
BBAS3.SA			138.745,90	7.749,18	6,76

Como pode ser observado no Quadro 2, foram realizados alguns testes individuais com cada ação para descobrir qual poderia ser o maior valor de retorno obtido por meio do investimento. Por fim, houve a tentativa de encontrar um valor de RSI para os momentos de compra e venda, na qual fossem iguais para as duas ações e mesmo assim, sendo possível obter algum lucro. Por meio do quadro é possível perceber que é difícil encontrar um único valor de RSI, que gere o maior lucro para cada uma das ações, como foi possível obter nos testes em que cada ação possui seus respectivos valores.

Na quinta coluna, foi realizada uma média de quanto foi possível obter de lucro no período de cinco anos. Neste caso ficou nítido que se utilizássemos os mesmos valores de RSI para ambas as ações, o retorno poderia acabar sendo menor em comparação ao máximo que ele pode chegar caso seja investido de maneira individual, utilizando configurações específicas de RSI. Sendo assim, concluímos que para as duas ações analisadas (BB e Itaú), não tem um único valor de RSI para o qual os dois obtenham o máximo de lucro ou que o lucro de uma ação seja equivalente ao lucro da outra.

Enquanto na sexta coluna, foi utilizada a fórmula da Taxa de Crescimento Anual Composta (do inglês, *Compound Annual Growth Rate* - CAGR), para encontrar o valor sobre a porcentagem de lucro anual de cada investimento, nesta fórmula foi utilizado o período de cinco anos sobre a variável que representa o tempo em anos, já sobre o valor final foi utilizado o resultado de cada investimento e o valor inicial foi representado pelo montante inicial de cem mil. As porcentagens encontradas são importantes para a comparação entre o rendimento da poupança e dos indicadores técnicos.

Pode-se verificar que ao analisar uma simulação utilizando poupança ou investindo independentemente no Banco do Brasil ou no Itaú, que o rendimento bruto das aplicações em ações em uma destas empresas (em torno de 9,170% do BB e 9,175% do Itaú de taxa média de crescimento anual composta) seria superior a um investimento realizado na poupança (cuja taxa média de crescimento anual composta foi de 5,02% ao ano). Ademais, verificando os resultados sobre as ações do ITUB4.SA e BBAS3.SA, mas quando aplicados utilizando os mesmo valores de indicadores técnicos, é possível visualizar que a porcentagem de lucro é 2,25% e 6,76%, respectivamente, logo nesses casos, o investimento na poupança só seria benéfico sobre a ação do Itaú.

4.2. Código com técnicas de aprendizado de máquina

Nesta sessão será abrangido sobre como foi realizado o desenvolvimento e os resultados obtidos através dos códigos que foram feitos utilizando abordagens como Máquina de Vetores de Suporte (SVM) e Redes Neurais (MLPClassifier), ambos estão utilizando a técnica de K-folds antes de realizar a predição.

Os dois códigos estão iniciando de maneira semelhante, eles baixam os dados referentes às ações, em seguida estão sendo preparadas algumas variáveis que serão utilizadas para o momento de treinamento e avaliação do modelo, que está ocorrendo dentro de um laço de repetição. Esse é um diferencial em relação aos códigos que estão utilizando apenas indicadores técnicos, para realizar as predições foi preciso separar uma quantidade de dados entre o que seria designado para apenas treinamento do modelo e uma certa quantidade para aplicar o que o modelo aprendeu, realizando assim uma simulação. Neste caso, foi separado quatro anos para realizar os treinamentos e após esses quatro, foram utilizados mais dois anos para a simulação, um exemplo desse funcionamento, é que em um dos casos de teste, utilizamos dados do início de dois mil e dezenove até o fim de dois mil e vinte dois, a fins de treinamento, e os dados do início de dois mil e vinte três até o fim de dois mil e vinte quatro ficaram responsáveis pela simulação.

Na Figura 9, está sendo demonstrado como o laço de repetição é responsável por selecionar o modelo a partir da técnica do K-folds, neste momento, está sendo criado a partir dos dados selecionados para treinamento, na qual é dividido em dez

folds, através de cada *fold* fazemos mais uma separação para treinamento e outro para teste.

Figura 9. Laço de repetição para seleção do melhor modelo

```
1 for train_index, test_index in kf.split(X_treino):
2     X_train, X_test = X_treino.iloc[train_index], X_treino.iloc[test_index]
3     y_train, y_test = Y_treino.iloc[train_index], Y_treino.iloc[test_index]
4
5     X_train_scaled = scaler.fit_transform(X_train)
6     X_test_scaled = scaler.transform(X_test)
7
8     model = SVC(kernel='linear')
9
10    model.fit(X_train_scaled, y_train)
11
12    predictions = model.predict(X_test_scaled)
13
14    accuracyAtual = accuracy_score(y_test, predictions)
15    # proporção de previsões corretas em relação ao total de exemplos
16
17    precisionAtual = precision_score(y_test, predictions)
18    # proporção de exemplos positivos previstos pelo modelo que são realmente positivos
19
20    f1Atual = f1_score(y_test, predictions)
21    # a média harmônica entre precisão e recall
22
23    if accuracyAtual >= melhorAcuracia:
24        melhorAcuracia = accuracyAtual
25        melhorPrecisao = precisionAtual
26        melhorF1 = f1Atual
27        melhorModelo = model
28    accuracy_scores.append(accuracyAtual)
```

Na Figura 9, é possível observar que para este caso estamos selecionando a ferramenta SVC (modelo SVM) para obter o melhor modelo e através dela obtivemos os valores referentes a sua *accuracy* (proporção de previsões corretas), *precision* (proporção de exemplos positivos) e a medida F (média harmônica entre precisão e *recall*), que nesse caso está sendo representada pela função *f1 score*.

Os códigos se diferenciam no momento em que selecionamos a ferramenta para ser utilizada de modelo. Na linha de número oito da Figura 9, é possível ver o momento que escolhemos a ferramenta SVC, porém além dela estamos utilizando o `MLPClassifier`, que de acordo com Scikit-Learn (2024), o SVC é um algoritmo de Máquina de Vetores de Suporte, que tem como objetivo encontrar o melhor hiperplano que separa as classes em um espaço multidimensional, enquanto o `MLPClassifier`, traduzindo é conhecido como um classificador de *perceptron* de multicamadas, ou seja, ele é uma rede neural artificial, na qual cada neurônio realiza uma combinação linear de suas entradas e aplica em uma função de ativação.

Ao fim, do laço de repetição é validado se a precisão atual é melhor que a do *fold* anterior, caso seja melhor, é salvo esse novo modelo, para quando for finalizado

todos os *folds* seja feita a simulação utilizando esse modelo já treinado anteriormente.

Com o fim do laço de repetição e tendo obtido o melhor modelo após a sequência de treinamento, é chamada a função que vai simular as operações de compra e venda sobre os dados de simulação, que foram limitados a um período de dois anos posteriores ao período de treinamento. Somente após a predição é possível verificar se o modelo treinado conseguiu obter algum lucro investido.

A lógica para essa função é a mesma que está sendo utilizada nos códigos que envolvem apenas os indicadores técnicos, a diferença é que nesse caso estamos uma lista chamada *predictions*, essa lista contém previsões feitas pelo melhor modelo, os valores presentes nesta lista são -1 que significa um momento de pode ser realizado uma venda, outro valor seria o 1, indicando um momento de compra e o último valor seria o 0, neste caso, é recomendado não realizar nenhuma ação e manter as ações como estão. Esses valores são importantes, pois como está sendo apresentado na Figura 10, eles estão decidindo qual deve ser a próxima ação que o código deve executar, no caso seria uma compra ou uma venda.

Figura 10. Momento de compra e venda decidido pelo *prediction*



```
1  predicacao = predictions[baseX_teste.index.get_loc(i)]
2
3  if fimDeAno:
4      if (predicacao == -1 and qtdAcoes > 0):
5          precoVenda = preco_fechamento
6          capital += qtdAcoes * precoVenda
7          qtdAcoes = 0
8          dataVendaFinal = i
9          break;
10
11     elif (predicacao == 1 and qtdAcoes == 0) :
12         dataVendaFinal = dataLastSell
13         break
14
15     else:
16         if predicacao == 1 and qtdAcoes == 0:
17             if capital >= preco_fechamento:
18                 qtdAcoes += capital // preco_fechamento
19                 capital %= preco_fechamento
20                 print(f"Compra: {qtdAcoes} ações a R$ {round(preco_fechamento, 2)} no dia {i}")
21
22         elif predicacao == -1 and qtdAcoes > 0:
23             capital += qtdAcoes * preco_fechamento
24             print(f"Venda: {qtdAcoes} ações a R$ {round(preco_fechamento, 2)} no dia {i}")
25             qtdAcoes = 0
26             dataLastSell = i
```

Pela Figura 10, é possível visualizar que estamos repetindo a lógica de realizar um venda final ao completar o período de um ano e assim ativando uma

variável de fim de ano, indicando o encerramento das transações, esta lógica está presente nos algoritmos que envolvem apenas indicadores técnicos, assim como é possível ver na Figura 5 e na Figura 8. Basicamente estamos seguindo o mesmo modelo de compra e venda que está presente nos códigos anteriores, porém desta vez estamos utilizando as previsões feitas pelo modelo de aprendizado de máquina.

As ferramentas SVC e MLPClassifier, ambas estão utilizando os dados de RSI, MACD e linha de sinal para que seus resultados sejam mais coerentes. Nos códigos envolvendo as técnicas de aprendizado de máquina, usamos como valor de janela do RSI o número quatorze, já para o MACD, foram empregados os valores doze para a janela de suavização da menor média móvel e vinte e seis para a segunda média. Obtidos esses valores encontramos o resultado do MACD e por fim, foi calculado mais uma média móvel exponencial, com o valor da janela de suavização igual a nove para encontrar o resultado da linha de sinal.

4.2.1. Código com SVM

O código que tem o seu funcionamento baseado na ferramenta SVC, está utilizando os parâmetros C igual a 1.0, este parâmetro está relacionado a penalidade sobre as violações da margem e o segundo parâmetro seria o modo kernel que está definido como linear.

Segundo Scikit-Learn (2024), caso utilizemos valores maiores para C, isso pode acabar desencadeando uma margem mais estreita e um modelo menos propenso a erros de classificação no conjunto de treinamento, porém, se utilizarmos valores menores de C, a margem acaba sendo mais ampla e o modelo se torna mais tolerante a erros de treinamento. Sobre o modo kernel, ele está indicando que a decisão de classificação será baseada em um hiperplano linear que separa os dados.

No Quadro 3, conseguimos observar os resultados que obtivemos através das ações ITUB4.SA e do BBAS3.SA.

Quadro 3. Resultados das simulações com SVM

	Período de Simulação					Média anual	Porcentagem de lucro anual (% a.a)
	(2019-2020)	(2020-2021)	(2021-2022)	(2022-2023)	(2023-2024)		
ITUB4.SA	98857,09	79665,9	67867,41	124817,36	98073,5	93856,25	-6,14
BBAS3.SA	124598,36	70096,81	102837,88	119194,35	134114,35	110168,35	10,1

Para os resultados presentes no Quadro 3, foram realizados cinco testes de maneira separada. Em cada um dos testes, estipulamos um período de treinamento de quatro anos e um período de dois anos para a simulação, nestes testes todos foram iniciados com um capital de cem mil reais e após realizado a última transação, é salvo qual foi o valor final daquele ano de investimento, para que o próximo teste seja feito sem interferência de valores anteriores.

4.2.2. Código com MLPClassifier

Além do código envolvendo SVC, foi desenvolvido um segundo código para comparar os possíveis lucros obtidos de cada um e ver qual conseguiu se adaptar melhor às ações. Esse segundo código está utilizando a ferramenta MLPClassifier, de acordo com Scikit-Learn (2024), que tem como parâmetros o *hidden_layer_sizes*, que basicamente define uma camada oculta com um determinado número de neurônios e para esses testes foi definido cinquenta neurônios, para este parâmetro o número de camadas ocultas e o de neurônios em cada camada, podem influenciar na capacidade do modelo de aprender padrões complexos.

O segundo parâmetro presente é o *activation*, que fica responsável por determinar a função de ativação para os neurônios, neste caso foi utilizado a função ReLU (Rectified Linear Unit), impactando assim diretamente no jeito como os neurônios processam as informações e influenciam a não-linearidade. Além disso, foi utilizado o parâmetro *solver* que tem como objetivo definir um algoritmo de otimização para ajustar os pesos da rede neural e para este trabalho foi utilizado o algoritmo Adam. Por último, temos um parâmetro denominado como *max_iter*, nele estamos apenas definindo o número máximo de iterações, que neste caso é igual a mil.

Através de alguns testes, obtivemos os seguintes resultados, que podem ser observados pelo Quadro 4.

Quadro 4. Resultados das simulações com MLPClassifier

	Período de Simulação					Média anual	Porcentagem de lucro anual (% a.a)
	(2019-2020)	(2020-2021)	(2021-2022)	(2022-2023)	(2023-2024)		
ITUB4.SA	96085,55	71448,7	68654,73	144654,32	104336,39	97035,93	-2,9
BBAS3.SA	109531,22	61268,65	100397,6	107555,96	128605,24	101471,73	1,4

É possível notar a partir dos resultados obtidos nos Quadros 3 e 4, que para ambos os modelos e ações, houve uma grande dificuldade de fazer previsões durante os períodos de dois mil e vinte até fim de dois mil e vinte e um. Essa dificuldade pode ter sido gerada pelo fato do início da pandemia ter sido em meados de dois mil e vinte e vinte e um, e como consequência o mercado sofreu diversas alterações causando uma instabilidade nos preços e uma dificuldade maior de previsão devido ter sido um evento de impacto global.

Por fim, no Quadro 5 foi realizado uma média entre os valores obtidos para a *accuracy*, *precision* e *F1-score*, que estiverem presentes em cada fold, a fim de entender a qualidade de cada modelo. Esses valores são os mesmos no código que utiliza a ferramenta SVC, tanto quanto a MLPClassifier, isso acontece porque são encontrados antes de realizar as predições sobre os dados de simulação.

Quadro 5. Valores de *accuracy*, *precision* e *F1-score*

Ações	Valor de Accuracy (0-1)	Valor de Precision (0-1)	Valor de F1-score (0-1)
ITUB4.SA	0,96	0,96	0,96
BBAS3.SA	0,98	0,98	0,98

5. Resultados

A partir da realização de diversos testes, com base nos dados coletados, foi realizada uma análise e por causa disso, foi feito o ranqueamento com base no percentual de lucro anual, sobre os melhores investimentos, assim como foi mostrado no Quadro 6, considerando diferentes estratégias e períodos. A análise abrangeu o rendimento financeiro da poupança (de acordo com o Banco Central do Brasil), o desempenho de ações utilizando indicadores técnicos, e os resultados obtidos com as técnicas de aprendizado de máquina, no caso o Support Vector Machine (SVM) e Multilayer Perceptron (MLPClassifier).

Por conta das diferentes técnicas que foram utilizadas em cada um dos casos de testes, no Quadro 6 temos uma coluna relacionada ao valor de lucro ao final dos testes, onde foi possível observar alguns resultados negativos, ou seja, ao fim do período de investimento houve uma perda sobre o valor inicial de cem mil reais. A última coluna é sobre a taxa média de crescimento anual composta (do inglês, *Compound Annual Growth Rate* - CAGR).

Quadro 6. Tabela de ranqueamento dos melhores investimentos

Rank	Estratégia	Ação	Valor Lucro Final (R\$)	CAGR (%)
1	SVM	BBAS3.SA	50.841,75	10,1
2	Indicadores Técnicos	ITUB4.SA	55.103,00	9,17
3	Indicadores Técnicos	BBAS3.SA	55.072,16	9,17
4	Poupança	—	27.806,66	5,02
5	MLPClassifier	BBAS3.SA	7.358,67	1,4
6	MLPClassifier	ITUB4.SA	-14.820,31	-2,9
7	SVM	ITUB4.SA	-30.718,74	-6,14

Visualizando o Quadro 6, conseguimos notar que a ação BBAS3.SA se destacou como a melhor opção de investimento sobre as técnicas utilizadas, sendo o melhor resultado em questão de valor final, o valor de R\$55.072,16, utilizando a estratégia de indicadores técnicos, já em questão de lucro anual, o código envolvendo SVM, obteve dez vírgula um por cento de lucro, sendo praticamente o dobro do lucro em relação ao valor da poupança.

Entretanto, a ação ITUB4.SA, não conseguiu obter nenhum lucro por meio das técnicas de aprendizado de máquina, diante disso, foi visto que ela não se adaptou bem aos mesmos parâmetros que foram utilizados na ação BBAS3.SA.

Por fim notamos que a poupança, mesmo apresentando um lucro não muito alto em comparação a algumas técnicas, ainda segue sendo uma opção mais segura e de menos riscos diante das situações como pandemias.

6. Conclusão

Durante o desenvolvimento desta pesquisa, foram adquiridos diversos conhecimentos, tanto na área de economia, buscando entender melhor como o mercado de ações funciona e algumas das técnicas comumente utilizadas. Além disso, foi de suma importância entender a teoria por trás do funcionamento das técnicas de aprendizado de máquina para que fosse possível o desenvolvimento dos modelos utilizados no decorrer desta pesquisa.

De modo a demonstrar a aplicação da análise técnica em detrimento da aprendizagem de máquina, foram selecionadas duas empresas de capital aberto do setor financeiro, o Itaú Unibanco Holding S.A. (ITUB4.SA), juntamente com o Banco do Brasil S.A. (BBAS3.SA). Cabe ressaltar, que as duas empresas, no período analisado, de acordo com o site Yahoo Finance (2024), acabaram sofrendo diversas alterações de valores durante o período da pandemia causada pela COVID-19.

Inicialmente, aplicamos dois indicadores técnicos de maneira separada para que pudéssemos compreender o seu funcionamento, porém foi visto que ambos tinham suas peculiaridades em agir, por exemplo a quantidade de compras realizadas em um mesmo período, assim não gerando resultados tão satisfatórios quanto o esperado. Por este motivo, optamos por combinar os dois modelos em apenas um e a partir disso, foi trabalhado com a alteração dos parâmetros que eram passados para esses indicadores. Dessa forma conseguimos obter resultados melhores, do que comparados aos modelos gerados que utilizam apenas um indicador. Após ter realizado estes testes, foi pesquisado sobre quanto estava sendo o rendimento anual da poupança, pois com esses valores conseguimos ter uma base de comparação mais sólida e real sobre os resultados obtidos por meio das simulações.

Com base na análise feita sobre o rendimento da poupança, conseguimos notar um bom rendimento sobre ações da BBAS3.SA e a ITUB4.SA, quando analisadas de maneira separada e buscando encontrar os melhores valores para os parâmetros dos modelos, porém quando utilizados os mesmos valores de parâmetros, foi observado uma queda considerável do rendimento, principalmente para a ação do Itaú, conseguindo ter um resultado pior que o da poupança. Em contrapartida, quando analisada a ação do Banco do Brasil, foi visto que ainda

manteve um lucro considerável e conseguindo ser melhor do que comparado ao da poupança.

Na sequência, foram desenvolvidos um modelo SVM e um segundo modelo de redes neurais MLPClassifier, este segundo modelo foi criado para ser usado mais como método comparativo ao que utilizava SVM, para treinamento de ambos os modelos, foi utilizada a técnica de K-folds. Foram feitos diversos testes para esses casos, por causa do aprendizado de máquinas, era necessário demandar mais tempo de treinamento, para somente em seguida realizar as simulações de predições. Entretanto, diante das simulações feitas, acabou sendo complicado encontrar valores de parâmetros que eram utilizados simultaneamente nos códigos e que geraram bons resultados de investimentos, ou pelo menos que fossem melhores que a poupança. Por esse motivo, foi obtido apenas da ação BBAS3.SA, em combinação com a técnica de SVM, teve um bom resultado, conseguindo superar a média de crescimento anual composta dos modelos que utilizavam indicadores técnicos e sobre o rendimento da poupança.

Foi observado que para esse cenário de pesquisa, a ação ITUB4.SA, não se adaptou tão bem aos modelos, quanto a ação do Banco do Brasil. Somente nos casos dos indicadores técnicos ela conseguiu ter um lucro. Diante disso, concluímos que existe uma grande dificuldade em encontrar bons resultados, quando se utiliza os mesmos parâmetros para duas ações distintas, mesmo que sejam sobre a mesma área, que neste caso, estavam se tratando de ações sobre bancos. Mas mesmo diante desta dificuldade, foi possível aplicar as técnicas envolvendo indicadores e comparar com modelos de aprendizado de máquinas, gerando investimentos melhores do que em relação à poupança.

Com relação às técnicas de SVM e MLPClassifier, foi encontrado uma segunda dificuldade enfrentada pelo modelo. Durante os testes, foi visto que quando a simulação ocorria no início do ano de dois mil e vinte, até o fim de dois mil e vinte um, os modelos só tiveram prejuízos. Vendo que o período para treinamento havia iniciado em dois mil e dezesseis e finalizado em dois mil e dezenove, acreditamos que por conta da pandemia da COVID-19 que se instaurou no início de dois mil e vinte, as ações acabaram sofrendo reações não esperadas, levando o modelo a ter dificuldades para predições sofre um cenário desconhecido e como consequência gerando péssimos resultados.

Tendo analisado os resultados obtidos, esperamos que para trabalhos futuros, que fossem continuação do mesmo, seria interessante um estudo mais aprofundado sobre um conjunto maior de empresas e de outros setores, dar mais foco a diversos casos de testes que busquem explorar vários parâmetros referente aos modelos, ou utilizar parâmetros diferentes dos que foram utilizados nesta pesquisa, a fim de buscar por resultados melhores. Uma outra opção, seria trabalhar com períodos diferentes de tempo para treinamento e simulação, buscando entender se é realmente necessário a utilização de períodos de quatro anos de treinamento para a simulação de apenas um. Também seria interessante a comparação com outras técnicas de aprendizado de máquina.

Referências Bibliográficas

AFONSO, Luis Paulo de Araújo. **RNA X SVM: Uma Análise na Decisão de Compras de Ações**. Trabalho de Conclusão de Curso, Universidade Estadual de Maringá, 2023.

BANCO CENTRAL DO BRASIL. **SGS Sistema Gerenciador de Séries Temporais -v2.1**, 2024.

BISHOP, Christopher M. **Pattern Recognition and Machine Learning**. Springer, 2006.

BRASIL INDICADORES. **Rendimento atual, acumulado e histórico da Poupança**, 2024.

COSTA, Israel Januth; VARGAS, Jaderson. Análise fundamentalista e análise técnica: agregando valor a uma carteira de ações. **Destarte**, v. 1, n. 1, p. 9–25, 2011.

CUNHA, João Paulo Zanola. **Um estudo comparativo das técnicas de validação cruzada aplicadas a modelos mistos**. Dissertação apresentada ao Instituto de Matemática e Estatística da Universidade de São Paulo para obtenção do título de mestre em ciências, 2019.

FARHAT, Ramzi; MOURALI, Yosra; JEMNI, Mohamed; EZZEDINE, Houcine. An overview of Machine Learning Technologies and their use in E-learning. **2020 International Multi-Conference on: “Organization of Knowledge and Advanced Technologies” (OCTA)**, 2020.

GRAHAM, B. **O Investidor Inteligente: Um Guia Clássico para Ganhar Dinheiro na Bolsa de Valores**. Editora HarperCollins, 2006.

KANG, Byung Kook. Improving MACD Technical Analysis by Optimizing Parameters and Modifying Trading Rules: Evidence from the Japanese Nikkei 225 Futures market. **Journal of Risk and Financial Management**, v. 14, n. 1, p. 1–21, 2021.

KONG, Ao; ZHU, Hongliang . Predicting Trend of High Frequency CSI 300 Index Using Adaptive Input Selection and Machine Learning Techniques. **Journal of Systems Science and Information**, vol. 6, pp. 120-133, 2018.

LEMOS, Flávio. **Análise Técnica dos Mercados Financeiros**. 3ª edição. Editora Saraiva Uni, 2012.

LIU, Huan-lu; HUANG, Kuo-Chan. A Deep Learning Model for Stock Price Prediction in Swing Trading. **2023 9th International Conference on Applied System Innovation (ICASI)**, 2023.

MURPHY, John J. **Análise Técnica do Mercado Financeiro: Guia definitivo e métodos de negociação**. Editora Alta Books, 2021.

RUSSELL, Stuart; NORVIG, Peter. **Inteligência Artificial: uma abordagem moderna**. Terceira edição. Editor Gen LTC, 2013.

SARIKA, V; SIVA KAMAL, G, V; PRATHAM, S, V; DEEPAK, N, V, S, S; VENEELA, T. An LSTM-Based Model for Stock Price Prediction. **2023 Annual International Conference on Emerging Research Areas: International Conference on Intelligent Systems (AICERA/ICIS)**, 2023.

SCIKIT-LEARN. **scikit-learn Machine Learning in Python**, 2024.

SILVA, João Vitor Malvestio. **Influência de Mercado da China na Predição do Movimento de Preço com Base em Técnicas de IA**. Trabalho de Conclusão de Curso, Universidade Estadual de Maringá, 2022.

TANNO, Douglas Rorie. **Análise do efeito lead-lag entre bolsas de valores do Japão e do Brasil**. Trabalho de Conclusão de Curso, Universidade Estadual de Maringá, 2022.

VAPNIK, Vladimir N. **The Nature of Statistical Learning Theory**. Second Edition, Springer, 2000.

YADAV, Sanjay; SHUKLA, Sanyam. **Analysis of k-Fold Cross-Validation over Hold-Out Validation on Colossal Datasets for Quality Classification**. IEEE 6th International Conference on Advanced Computing (IACC), 2016.

YAHOO FINANCE. **Yahoo Finance - Stock Market Live, Quotes, Business & Finance News**, 2024.

ZOUAGHIA, Zakia; AOUINA, Zahra Kodia; SAID, Lamjed Ben. Stock Movement Prediction Based On Technical Indicators Applying Hybrid Machine Learning Models. **2023 International Symposium on Networks, Computers and Communications (ISNCC)**, 2023.